

Лекция 11

5. Численные методы многомерной оптимизации

5.1. Выпуклые множества и выпуклые функции

Пусть $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$. Множество

$$[\mathbf{x}, \mathbf{y}] = \{\alpha\mathbf{x} + (1 - \alpha)\mathbf{y} : \alpha \in [0, 1]\} \quad (1.1)$$

называется *отрезком*, соединяющим точки \mathbf{x} и \mathbf{y} .

Множество $X \subset \mathbb{R}^n$ называется *выпуклым*, если вместе с любыми точками \mathbf{x} и $\mathbf{y} \in X$ оно содержит и весь отрезок $[\mathbf{x}, \mathbf{y}]$.

Множество \mathbb{R}^n , очевидно, является выпуклым множеством. Пустое множество \emptyset считается выпуклым множеством.

Теорема 1. Пусть I — любое, конечное или бесконечное, множество индексов, X_i ($i \in I$) — выпуклые множества. Тогда их пересечение $X = \bigcap_{i \in I} X_i$ выпукло.

Доказательство. Пусть $X \neq \emptyset$ и $\mathbf{x}, \mathbf{y} \in X$, $\alpha \in [0, 1]$. По определению пересечения для любого $i \in I$ имеем $\mathbf{x}, \mathbf{y} \in X_i$ и значит $\mathbf{z} = \alpha\mathbf{x} + (1 - \alpha)\mathbf{y} \in X_i$ так как X_i выпукло. Тогда $\mathbf{z} \in \bigcap_{i \in I} X_i = X$, т.е. X выпукло. ■

Функция $f(\mathbf{x})$, заданная на выпуклом множестве $X \subset \mathbb{R}^n$, называется *выпуклой*, если для любых точек $\mathbf{x}, \mathbf{y} \in X$ и любого $\alpha \in [0, 1]$ выполняется неравенство

$$f(\alpha\mathbf{x} + (1 - \alpha)\mathbf{y}) \leq \alpha f(\mathbf{x}) + (1 - \alpha)f(\mathbf{y}). \quad (1.2)$$

Функция $f(\mathbf{x})$ называется *строго выпуклой* если всех $\alpha \in (0, 1)$ неравенство (1.2) выполняется как строгое.

Теорема 2. Линейная комбинация выпуклых на выпуклом множестве X функций $f_i(\mathbf{x})$, $i = 1, \dots, m$, с неотрицательными коэффициентами λ_i , т.е.

$$f(\mathbf{x}) = \sum_{i=1}^m \lambda_i f_i(\mathbf{x}), \quad \lambda_i \geq 0,$$

есть выпуклая на множестве X функция.

Доказательство. Для любых $\mathbf{x}, \mathbf{y} \in X$, $\alpha \in [0, 1]$ имеем

$$\begin{aligned} f(\alpha\mathbf{x} + (1 - \alpha)\mathbf{y}) &= \sum_{i=1}^m \lambda_i f_i(\alpha\mathbf{x} + (1 - \alpha)\mathbf{y}) \leq \\ &\leq \sum_{i=1}^m \lambda_i (\alpha f_i(\mathbf{x}) + (1 - \alpha)f_i(\mathbf{y})) = \alpha f(\mathbf{x}) + (1 - \alpha)f(\mathbf{y}), \end{aligned}$$

т.е. выполняется (1.2). Значит, функция $f(\mathbf{x})$ выпукла. ■

Теорема 3. Пусть $f(\mathbf{x})$ — выпуклая функция, заданная в пространстве \mathbb{R}^n . Тогда множество

$$X = \{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) \leq b\}$$

выпукло.

Доказательство. Пусть $\mathbf{x}, \mathbf{y} \in X$ и $\mathbf{z} = \alpha\mathbf{x} + (1-\alpha)\mathbf{y}$, $\alpha \in [0, 1]$. Из выпуклости функции $f(\mathbf{x})$ следует, что $f(\mathbf{z}) \leq \alpha f(\mathbf{x}) + (1-\alpha)f(\mathbf{y}) \leq b$, т. е. $\mathbf{z} \in X$ и множество X — выпукло. ■

Следствие. Пусть $f_i(\mathbf{x})$, $i = 1, \dots, m$, — выпуклые функции в \mathbb{R}^n . Тогда множество точек \mathbf{x} , удовлетворяющих системе неравенств

$$f_i(\mathbf{x}) \leq b_i, \quad i = 1, \dots, m,$$

выпукло.

Доказательство. Это следует из теорем 3.1 и 3.3. ■

Приведём свойства выпуклых функций, играющих важную роль в вопросах минимизации.

Теорема 4. Пусть $f(\mathbf{x})$ — выпуклая функция, заданная на выпуклом множестве X . Тогда любой её локальный минимум на множестве X является одновременно и глобальным.

Доказательство. Предположим противное, т. е. пусть \mathbf{x}_0 — точка локального, а \mathbf{x}_* — точка глобального минимума $f(\mathbf{x})$ на множестве X , $\mathbf{x}_* \neq \mathbf{x}_0$ и $f(\mathbf{x}_0) > f(\mathbf{x}_*)$. Отсюда с учётом выпуклости функции имеем:

$$f(\alpha\mathbf{x}_* + (1-\alpha)\mathbf{x}_0) \leq \alpha f(\mathbf{x}_*) + (1-\alpha)f(\mathbf{x}_0) < f(\mathbf{x}_0).$$

При $\alpha \rightarrow +0$ точка $\mathbf{x} = \alpha\mathbf{x}_* + (1-\alpha)\mathbf{x}_0$ попадёт в сколь угодно малую окрестность точки \mathbf{x}_0 . Поэтому полученное неравенство $f(\mathbf{x}) < f(\mathbf{x}_0)$ противоречит предположению о том, что \mathbf{x}_0 — точка локального минимума. ■

Теорема 5. Глобальный минимум строго выпуклой функции $f(\mathbf{x})$, заданной на выпуклом множестве X , может достигаться лишь в единственной точке.

Доказательство. Предположим, что \mathbf{x}_1 и \mathbf{x}_2 — две различные точки глобального минимума. Из строгой выпуклости $f(\mathbf{x})$ следует, что для всех $\alpha \in (0, 1)$ выполняется строгое неравенство

$$f(\alpha\mathbf{x}_1 + (1-\alpha)\mathbf{x}_2) < \alpha f(\mathbf{x}_1) + (1-\alpha)f(\mathbf{x}_2) = f_* = \min_{\mathbf{x} \in X} f(\mathbf{x}),$$

что противоречит предположению о том, что точки \mathbf{x}_1 и \mathbf{x}_2 — точки глобального минимума. ■

Функция $f(\mathbf{x})$, заданная в пространстве \mathbb{R}^n , называется *сильно выпуклой*, если существует такое число $l > 0$ (константа сильной выпуклости), что для всех \mathbf{x} и $\mathbf{y} \in \mathbb{R}^n$ и любого $\alpha \in [0, 1]$ выполняется неравенство:

$$f(\alpha\mathbf{x} + (1-\alpha)\mathbf{y}) \leq \alpha f(\mathbf{x}) + (1-\alpha)f(\mathbf{y}) - \alpha(1-\alpha)l|\mathbf{x} - \mathbf{y}|^2. \quad (1.3)$$

5.2. Выпуклые квадратичные функции

Функция вида

$$f(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_i x_j + \sum_{j=1}^n b_j x_j + c \quad (2.1)$$

называется *квадратичной функцией n переменных*. Положив $a_{ij} = \alpha_{ij} + \alpha_{ji}$, получим симметрическую матрицу $A = (a_{ij})$, с помощью которой выражение (2.1) можно записать в другой форме

$$f(\mathbf{x}) = \frac{1}{2} \langle A\mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{b}, \mathbf{x} \rangle + c \quad (2.2)$$

где $\mathbf{b} = (b_1, \dots, b_n)^t \in \mathbb{R}^n$ — вектор коэффициентов b_j .

Пример 1. Функция

$$f(\mathbf{x}) = 2x_1^2 - 2x_1x_2 + 3x_1x_3 + x_2^2 - 2x_2x_3 + 4x_3^2 + x_1 - x_2 + 3x_3 + 5$$

является квадратичной. Запишем её матрицу A , вектор \mathbf{b} и коэффициент c из (2.2):

$$A = \begin{pmatrix} 4 & -2 & 3 \\ -2 & 2 & -2 \\ 3 & -2 & 8 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 1 \\ -1 \\ 3 \end{pmatrix}, \quad c = 5.$$

Перечислим основные свойства квадратичных функций.

1. Для градиента квадратичной функции справедлива формула:

$$\nabla f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}. \quad (2.3)$$

Доказательство. Имеем

$$\begin{aligned} \frac{\partial}{\partial x_k} \sum_{i=1}^n \sum_{j=1}^n \alpha_{ij} x_i x_j &= \frac{\partial}{\partial x_k} \left\{ \sum_{i=1}^n \alpha_{ii} x_i^2 + \sum_{i \neq j} \alpha_{ij} x_i x_j \right\} = \\ &= 2\alpha_{kk} x_k + \sum_{i \neq k} (\alpha_{ik} + \alpha_{ki}) x_i = 2 \sum_{i=1}^n a_{ki} x_i = 2(A\mathbf{x})_k \end{aligned}$$

Далее

$$\frac{\partial}{\partial x_k} \sum_{j=1}^n b_j x_j = b_k.$$

Следовательно, равенство (2.3) доказано. ■

2. Матрица Гессе квадратичной функции (2.2) совпадает с матрицей A :

$$f''(\mathbf{x}) = A. \quad (2.4)$$

Доказательство. Вычислим элемент матрицы Гессе:

$$\frac{\partial^2 f(\mathbf{x})}{\partial x_l \partial x_k} = \frac{\partial}{\partial x_l} \left(\frac{\partial f(\mathbf{x})}{\partial x_k} \right) = \frac{\partial}{\partial x_l} \left(\sum_{i=1}^n a_{ki} x_i + b_k \right) = a_{kl}.$$

Равенство (2.4) доказано. ■

2. Квадратичной функция (2.2) с положительно определённой матрицей A сильно выпукла.

Доказательство. ■

Пример 2. Рассмотрим квадратичную функцию из примера 1. Матрица Гессе $f''(\mathbf{x}) = A$ — положительно определена, так как

$$\Delta_1 = 4 > 0; \quad \Delta_2 = \begin{vmatrix} 4 & -2 \\ -2 & 2 \end{vmatrix} = 4 > 0; \quad \Delta_3 = \det A = 22 > 0.$$

Следовательно, $f(\mathbf{x})$ сильно выпукла по свойству 3 квадратичных функций.

5.3. Общие принципы n -мерной минимизации

Для численного решения задач безусловной минимизации:

$$f(\mathbf{x}) \rightarrow \min, \quad \mathbf{x} \in \mathbb{R}^n$$

разработано много алгоритмов, использующих итерационные процедуры вида

$$\mathbf{x}^{k+1} = \Phi(\mathbf{x}^k, \mathbf{x}^{k-1}, \dots, \mathbf{x}^0), \quad \mathbf{x}^0 \in \mathbb{R}^n, \quad (3.1)$$

позволяющие при определённых условиях построить последовательность $\{\mathbf{x}^k\}$ такую, что

$$\lim_{k \rightarrow \infty} f(\mathbf{x}^k) = \begin{cases} f_* = \min_{\mathbb{R}^n} f(\mathbf{x}), & X_* \neq \emptyset, \\ f_* = \inf_{\mathbb{R}^n} f(\mathbf{x}), & X_* = \emptyset, \end{cases} \quad (3.2)$$

где X_* — множество точек глобального минимума функции $f(\mathbf{x})$. Последовательность $\{\mathbf{x}^k\}$, удовлетворяющая требованию (3.2), называется *минимизирующей* для функции $f(\mathbf{x})$.

Минимизирующая последовательность может и не сходиться к точке минимума (см. пример 4.1.3). Важной характеристикой сходящихся минимизирующих последовательностей является *скорость сходимости*.

Последовательность $\{\mathbf{x}^k\}$ сходится к точке \mathbf{x}_* *линейно* (со скоростью геометрической прогрессии), если существует такое число $q \in (0, 1)$, что выполняется неравенство

$$|\mathbf{x}^k - \mathbf{x}_*| \leq q |\mathbf{x}^{k-1} - \mathbf{x}_*| \quad (3.3)$$

Последовательность $\{\mathbf{x}^k\}$ сходится к точке \mathbf{x}_* *сверхлинейно*, если

$$|\mathbf{x}^k - \mathbf{x}_*| \leq q_k |\mathbf{x}^{k-1} - \mathbf{x}_*|, \quad q_k \rightarrow +0, \quad k \rightarrow \infty. \quad (3.4)$$

Последовательность $\{\mathbf{x}^k\}$ сходится к точке \mathbf{x}_* с *квадратичной скоростью*, если существует константа C такая, что

$$|\mathbf{x}^k - \mathbf{x}_*| \leq C |\mathbf{x}^{k-1} - \mathbf{x}_*|^2. \quad (3.5)$$

Конкретный вычислительный процесс на основе (3.1), в котором может получаться, вообще говоря, бесконечная последовательность $\{\mathbf{x}^k\}$, необходимо дополнять условием остановки (критерием окончания счёта). На практике часто пользуются следующими условиями:

$$|\mathbf{x}^{k+1} - \mathbf{x}^k| < \varepsilon_1, \quad (3.6)$$

$$|f(\mathbf{x}^{k+1}) - f(\mathbf{x}^k)| < \varepsilon_2, \quad (3.7)$$

$$|\nabla f(\mathbf{x}^k)| < \varepsilon_3, \quad (3.8)$$

где $\varepsilon_1, \varepsilon_2, \varepsilon_3$ — заранее заданные параметры точности.

Ниже будут рассматриваться вычислительные алгоритмы простейших процедур (3.1), основанные на рекуррентных формулах вида

$$\mathbf{x}^{k+1} = \mathbf{x}^k + \alpha_k \mathbf{p}^k, \quad k = 0, 1, \dots, \quad (3.9)$$

где \mathbf{p}^k — направление поиска точки \mathbf{x}^{k+1} из точки \mathbf{x}^k , а число α_k — величина шага, которая выбирается так, чтобы выполнялось условие

$$f(\mathbf{x}^{k+1}) < f(\mathbf{x}^k). \quad (3.10)$$

Эти алгоритмы различаются способом построения вектора \mathbf{p}^k и выбора шага α_k .

Будем говорить, что в итерационном процессе (3.9) производится *исчерпывающий спуск*, если величина шага α_k находится из решения одномерной задачи минимизации

$$\Phi_k(\alpha) \rightarrow \min, \quad \Phi_k(\alpha) = f(\mathbf{x}^k + \alpha \mathbf{p}^k). \quad (3.11)$$

Таким образом, при исчерпывающем спуске на каждом шаге полностью реализуется возможность уменьшить значение целевой функции $f(\mathbf{x})$ при перемещении из точки \mathbf{x}^k в направлении \mathbf{p}^k . Величина шага α_k может быть найдена методами одномерной оптимизации.

Теорема 1. Для дифференцируемой в \mathbb{R}^n функции $f(\mathbf{x})$ в итерационном процессе (3.9) с выбором шага α_k в соответствии с (3.11) для всех $k \geq 1$ выполняется условие

$$\langle \nabla f(\mathbf{x}^{k+1}), \mathbf{p}^k \rangle = 0. \quad (3.12)$$

Доказательство. Запишем необходимое условие минимума функции одной переменной $\Phi_k(\alpha)$ из (3.11):

$$\frac{d\Phi_k(\alpha)}{d\alpha} = \sum_{j=1}^n \frac{\partial f(\mathbf{x}^{k+1})}{\partial x_j} \frac{dx_j^{k+1}}{d\alpha} = 0.$$

Учитывая, что $x_j^{k+1} = x_j^k + \alpha p_j^k$, получаем условие (3.12). ■

Свойство (3.12) позволяет в явном виде найти величину α_k для квадратичной функции.

Теорема 2. Для квадратичной функции

$$f(\mathbf{x}) = \frac{1}{2} \langle A\mathbf{x}, \mathbf{x} \rangle + \langle \mathbf{b}, \mathbf{x} \rangle + c$$

величина α_k исчерпывающего спуска в итерационном процессе (3.9) будет

$$\alpha_k = - \frac{\langle \nabla f(\mathbf{x}^k), \mathbf{p}^k \rangle}{\langle A\mathbf{p}^k, \mathbf{p}^k \rangle} = - \frac{\langle A\mathbf{x}^k + \mathbf{b}, \mathbf{p}^k \rangle}{\langle A\mathbf{p}^k, \mathbf{p}^k \rangle} \quad (3.13)$$

Доказательство. Умножив равенство (3.9) слева на матрицу A квадратичной функции $f(\mathbf{x})$ и прибавив к обеим частям вектор \mathbf{b} , получим:

$$A\mathbf{x}^{k+1} + \mathbf{b} = A\mathbf{x}^k + \mathbf{b} + \alpha_k A\mathbf{p}^k.$$

Учитывая, что $\nabla f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}$, имеем $\nabla f(\mathbf{x}^{k+1}) = \nabla f(\mathbf{x}^k) + \alpha_k A\mathbf{p}^k$. Подставляя выражение для $\nabla f(\mathbf{x}^{k+1})$ в равенство (3.12), получаем формулу (3.13). ■

Направление вектора \mathbf{p} называется *направлением убывания* функции $f(\mathbf{x})$ в точке \mathbf{x} , если при всех достаточно малых $\alpha > 0$ выполняется неравенство $f(\mathbf{x} + \alpha \mathbf{p}) < f(\mathbf{x})$.

Теорема 3. Пусть функция $f(\mathbf{x})$ дифференцируема в точке \mathbf{x}^k . Если вектор \mathbf{p}^k удовлетворяет условию

$$\langle \nabla f(\mathbf{x}^k), \mathbf{p}^k \rangle < 0, \quad (3.14)$$

то направление вектора \mathbf{p}^k является направлением убывания.

Доказательство. Из дифференцируемости функции $f(\mathbf{x})$ и условия (3.14) следует, что

$$f(\mathbf{x}^k + \alpha \mathbf{p}^k) - f(\mathbf{x}^k) = \langle \nabla f(\mathbf{x}^k), \alpha \mathbf{p}^k \rangle + o(\alpha) = \alpha \left(\langle \nabla f(\mathbf{x}^k), \mathbf{p}^k \rangle + \frac{o(\alpha)}{\alpha} \right) < 0$$

при достаточно малых $\alpha > 0$. Таким образом, мы видим, что вектор \mathbf{p}^k задаёт направлением убывания функции $f(\mathbf{x})$. ■

Лекция 12

5.4. Метод (циклического) покоординатного спуска

Этот метод заключается в последовательной минимизации целевой функции $f(\mathbf{x})$ сначала по направлению первого базисного вектора \mathbf{e}^1 , затем второго — \mathbf{e}^2 и т.д. После окончания минимизации по направлению последнего базисного вектора \mathbf{e}^n цикл повторяется.

Опишем этот алгоритм.

0. Выбрать $\mathbf{x} \in \mathbb{R}^n$, критерий достижения точности (например, (3.6) или (3.7)), величину ε . Найти $f(\mathbf{x})$, положить $j = 1$.

1. Решить задачу одномерной оптимизации

$$\Phi(\alpha) = f(\mathbf{x} + \alpha \mathbf{e}^j) \rightarrow \min, \quad \alpha \in \mathbb{R},$$

т.е. найти α_* . Положить $\hat{\mathbf{x}} = \mathbf{x} + \alpha_* \mathbf{e}^j$, вычислить $f(\hat{\mathbf{x}})$.

2. Если $j < n$, то положить $\mathbf{x} = \hat{\mathbf{x}}$, $j = j + 1$ и перейти к **1**, иначе — перейти к **3**.

3. Проверить условие достижения точности $|\mathbf{x} - \hat{\mathbf{x}}| < \varepsilon$ или $|f(\mathbf{x}) - f(\hat{\mathbf{x}})| < \varepsilon$. Если оно выполняется, то положить $\mathbf{x}_* = \hat{\mathbf{x}}$, $f_* = f(\hat{\mathbf{x}})$ и закончить поиск. Иначе — положить $\mathbf{x} = \hat{\mathbf{x}}$, $f(\mathbf{x}) = f(\hat{\mathbf{x}})$, $j = 1$ и перейти к **1**.

Пример 1. Рассмотрим задачу

$$f(\mathbf{x}) = x_1^2 + x_2^2 \rightarrow \min, \quad \mathbf{x} \in \mathbb{R}^2.$$



Линии уровня этой целевой функции — окружности с центром в начале координат. Выберем произвольную начальную точку \mathbf{x} , например $\mathbf{x} = (3, 3)^t$. Очевидно, два шага исчерпывающего спуска сначала по направлению \mathbf{e}^1 , затем — \mathbf{e}^2 приведут в точку минимума $((3, 3) \rightarrow (0, 3) \rightarrow (0, 0))$.

Пример 2. Рассмотрим задачу

$$f(\mathbf{x}) = 5x_1^2 + 8x_1x_2 + 5x_2^2 \rightarrow \min, \quad \mathbf{x} \in \mathbb{R}^2..$$

Ниже приведены результаты 5 итераций алгоритма покоординатного спуска.

	x_1	x_2	$f(\mathbf{x})$
0	5	5	450
1 ₁	-4	5	45
1 ₂	-4	3.2	28.8
2 ₁	-2.56	3.2	18.432
2 ₂	-2.56	2.048	11.79648
3 ₁	-1.6384	2.048	7.54975
3 ₂	-1.6384	1.31072	4.83183
4 ₁	-1.04858	1.31072	3.09238
4 ₂	-1.04858	0.83886	1.97912
5 ₁	-0.67109	0.83886	1.26664
5 ₂	-0.67109	0.53687	0.81065



5.5. Метод градиентного спуска

Все итерационные процессы вида

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k), \quad \alpha_k > 0, \quad k = 0, 1, \dots, \quad (5.1)$$

в которых направление движения совпадает с антиградиентом функции, называются *градиентными методами* и отличаются друг от друга способами выбора шага α_k .

Существуют много различных способов выбора α_k , но наиболее распространены два: первый называется *методом с дроблением шага* и связан с проверкой на каждой итерации некоторого неравенства; во втором производится исчерпывающий спуск — *метод наискорейшего спуска*.

Рассмотрим процесс (5.1). Первая проблема, которая возникает при его реализации, — это выбор шага α_k . Достаточно малый шаг α_k обеспечит убывание функции, т. е. выполнение неравенства

$$f(\mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k)) < f(\mathbf{x}^k), \quad (5.2)$$

но может привести к неприемлемо большому количеству итераций, необходимых для достижения точки минимума. С другой стороны, слишком большой шаг может вызвать неожиданный рост функции (невыполнение условия (5.2)) либо привести к колебаниям около точки минимума.

Пример 1. Рассмотрим задачу минимизации функции $f(x) = ax^2$, где a — некоторое положительное число. Тогда формула (5.1) принимает вид


$$x^{k+1} = x^k - \alpha_k \cdot 2ax^k = (1 - 2\alpha_k a)x^k.$$

Очевидно, что при постоянном шаге α_k соответствующий процесс будет сходиться, если $0 < \alpha_k < 1/a$, и расходиться для $\alpha_k > 1/a$. Если положить $\alpha_k = 1/a$, то $x_1 = -x_0$, $x_2 = x_0$, $x_3 = -x_0$ и т. д. Процесс будет расходящимся.

В методе градиентного спуска с дроблением шага величина α_k выбирается так, чтобы было выполнено следующее неравенство:

$$f(\mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k)) - f(\mathbf{x}^k) \leq -\varepsilon \alpha_k |\nabla f(\mathbf{x}^k)|^2, \quad (5.3)$$

где $0 < \varepsilon < 1$ — произвольно выбранная постоянная (одна и та же для всех итераций). Очевидно, что требование (5.3) на выбор шага более жёсткое, чем условие (5.2), но имеет тот же смысл: функция должна убывать от итерации к итерации.




Процесс (5.1) с выбором шага, удовлетворяющего неравенству (5.3), протекает следующим образом. Выбираем число $\alpha > 0$, одно и то же для всех итераций. На k -й итерации проверяем выполнение неравенства (5.3) при $\alpha_k = \alpha$. Если оно выполнено, полагаем $\alpha_{k+1} = \alpha$ и переходим к следующей итерации. Если нет, то шаг α_k дробим до тех пор, пока оно не выполнится. Геометрически градиентный спуск с дроблением шага изображен на рисунке. Здесь изображены линии уровня функции $f(\mathbf{x})$, имеющей минимум в точке x_* , причём $C_1 > C_2 > C_3 > \dots$, и некоторая зигзагообразная траектория $x_0 x_1 \dots x_k$, ортогональная в каждой точке x_0, x_1, \dots, x_k соответствующим линиям уровня и приводящая из начальной точки x_0 в точку минимума x_* .

5.6. Метод наискорейшего спуска

Процесс, на каждой итерации которого шаг выбирается из условия минимума функции $f(\mathbf{x})$ в направлении движения, т. е.

$$f(\mathbf{x}^k - \alpha_k \nabla f(\mathbf{x}^k)) = \min_{\alpha \geq 0} f(\mathbf{x}^k - \alpha \nabla f(\mathbf{x}^k)), \quad (6.1)$$

называется *методом наискорейшего спуска*. В этом варианте градиентного спуска на каждой итерации требуется решать задачу одномерной минимизации. Разумеется, этот способ выбора α_k сложнее, чем рассмотренные в предыдущем пункте.



Геометрическая интерпретация метода наискорейшего спуска представлена на рисунке. В этом методе, в отличие от обычного градиентного спуска, направление движения из точки x_k касается линии уровня в точке x_{k+1} . Последовательность точек $x_0, x_1, \dots, x_k, \dots$ зигзагообразно приближается к точке минимума x_* , причём звенья

этого зигзага ортогональны между собой. В самом деле, шаг α выбирается из условия минимизации по α функции

$$\varphi(\alpha) = f(\mathbf{x}^k - \alpha \nabla f(\mathbf{x}^k)),$$

и поэтому

$$\frac{d\varphi(\alpha_k)}{d\alpha} = -\nabla f(\mathbf{x}^{k+1}) \nabla f(\mathbf{x}^k) = 0.$$

Таким образом, направления спуска на двух последовательных итерациях взаимно ортогональны.

Пример 1. Рассмотрим функцию $f(\mathbf{x}) = x_1^2 + 100x_2^2$ и используем метод наискорейшего спуска для решения задачи её минимизации из начальной точки $\mathbf{x}^0 = (1, 1)^t$. Имеем

	x_1	x_2	$f(\mathbf{x})$	$\nabla f(\mathbf{x})$
0	1	1	101	200.01
1	0.9899990	-0.0000990	0.9800990	1.9800970
2	0.00970397	0.00970396	0.00951085	1.9408890
3	0.00960692	$-9.6069 \cdot 10^{-7}$	0.00009229	0.0192148

5.7. Метод Ньютона

Пусть функция $f(\mathbf{x})$ дважды дифференцируема в \mathbb{R}^n . Тогда для неё можно записать разложение по формуле Тейлора в окрестности точки \mathbf{x}^k :

$$f(\mathbf{x}) = f(\mathbf{x}^k) + \langle f'(\mathbf{x}^k), \mathbf{x} - \mathbf{x}^k \rangle + \frac{1}{2} \langle f''(\mathbf{x}^k)(\mathbf{x} - \mathbf{x}^k), \mathbf{x} - \mathbf{x}^k \rangle + o(|\mathbf{x} - \mathbf{x}^k|^2). \quad (7.1)$$

Отсюда видно, что поведение функции $f(\mathbf{x})$ с точностью до величины порядка $o(|\mathbf{x} - \mathbf{x}^k|^2)$ может быть описано квадратичной функцией

$$\Phi_k(\mathbf{x}) = \frac{1}{2} \langle f''(\mathbf{x}^k)(\mathbf{x} - \mathbf{x}^k), (\mathbf{x} - \mathbf{x}^k) \rangle + \langle f'(\mathbf{x}^k), \mathbf{x} - \mathbf{x}^k \rangle + f(\mathbf{x}^k). \quad (7.2)$$

Минимизируем функцию $\Phi_k(\mathbf{x})$ вместо $f(\mathbf{x})$. Найдём её точку минимума \mathbf{x}^{k+1} из условия $\Phi'_k(\mathbf{x}) = 0$:

$$\Phi'_k(\mathbf{x}) = f''(\mathbf{x}^k)(\mathbf{x} - \mathbf{x}^k) + f'(\mathbf{x}^k) = 0. \quad (7.3)$$

Пусть матрица Гессе $f''(\mathbf{x})$ положительно определена при всех $\mathbf{x} \in \mathbb{R}^n$ и, следовательно, невырождена ($\det f''(\mathbf{x}) > 0$). Тогда существует обратная матрица $[f''(\mathbf{x})]^{-1}$. Отметим, что квадратичная функция (7.2) с положительно определённой матрицей $f''(\mathbf{x}^k)$ сильно выпукла и уравнение (7.3) определяет единственную точку глобального минимума функции $\Phi_k(\mathbf{x})$. Умножим слева обе части равенства (7.3) на матрицу $[f''(\mathbf{x}^k)]^{-1}$ и найдём точку минимума \mathbf{x}^{k+1} квадратичной функции (7.2), аппроксимирующей $f(\mathbf{x})$ в окрестности точки $\mathbf{x} = \mathbf{x}^k$:

$$\mathbf{x}^{k+1} = \mathbf{x}^k - [f''(\mathbf{x}^k)]^{-1} \cdot f'(\mathbf{x}^k), \quad k = 0, 1, \dots \quad (7.5)$$

Итерационный процесс (7.5), начатый из произвольной точки $\mathbf{x}^0 \in \mathbb{R}^n$, называется *методом Ньютона минимизации функции многих переменных*.

Очевидно, что для квадратичной функции с положительно определённой матрицей A применение метода Ньютона обеспечивает получение точки глобального минимума ровно за один шаг из любой точки $\mathbf{x}^0 \in \mathbb{R}^n$.

Недостатком метода Ньютона является необходимость вычисления и обращения матрицы Гессе на каждой итерации.